FitTrack: microservicios en Docker Swarm y análisis distribuido con Apache Spark

Integrante 1, Integrante 2, Integrante 3, Integrante 4, Integrante 5
Curso de Redes e Infraestructura
Universidad Autónoma de Occidente
Cali, Colombia
Noviembre de 2026

***Resumen*—Este trabajo presenta el despliegue de FitTrack, una aplicación de seguimiento físico basada en microservicios y API REST, sobre un clúster Docker Swarm de dos nodos, y la construcción de un pipeline de análisis de datos con Apache Spark que alimenta un dashboard. La aplicación se empaquetó en seis servicios y tres bases de datos, con HAProxy como punto de entrada y balanceo. El pipeline procesa un dataset sintético de 100.000 usuarios y 8,4 millones de filas, aplica limpieza de duplicados, fechas y unidades, y calcula KPIs de retención, adherencia, metas y evolución de peso. Los resultados se publican por una API y se muestran en una pestaña "Analítica". Las pruebas de carga muestran una mejora de 1,89× en RPS al pasar de una a tres réplicas, y la validación contra los patrones sembrados confirma que el análisis recupera las señales del dataset. El trabajo documenta las decisiones, los problemas encontrados y una guía reproducible.**

***Index Terms*—Docker Swarm, microservicios, Apache Spark, análisis distribuido, HAProxy, dashboard, reproducibilidad.**

I. Introducción

El módulo de Redes e Infraestructura cubre el empaquetado de aplicaciones, el despliegue en clústeres de contenedores y el procesamiento de datos a gran escala. El proyecto final integra esas tres dimensiones sobre una aplicación real: FitTrack, una aplicación de seguimiento físico con servicios de usuarios, medidas, progreso, rutinas y metas.

El objetivo general es desplegar la aplicación en un clúster de contenedores con escalabilidad y balanceo, y construir un pipeline de análisis distribuido que genere reportes consumidos por el dashboard. Los objetivos específicos son: (1) empaquetar los microservicios y sus bases de datos en imágenes reproducibles; (2) desplegar el stack en Docker Swarm con HAProxy; (3) diseñar y ejecutar un ETL con Spark sobre un dataset de gran escala; (4) calcular KPIs de interés y validarlos contra patrones conocidos; (5) publicar los resultados por una API y mostrarlos en el dashboard; y (6) medir funcionamiento, escalabilidad y desempeño, documentando la reproducción.

La contribución principal es una solución completa y reproducible que separa la aplicación transaccional (microservicios y bases de datos) del procesamiento analítico (Spark y archivos Parquet/JSON), con evidencia de funcionamiento y de escalado.

Cuadro I: Alternativas evaluadas y decisión.

Dimensión	Decisión y motivo
Orquestación	**Swarm**: ya estaba inicializado, es nativo de Docker y suficiente para dos nodos. Kubernetes habría exigido más recursos y complejidad.
Balanceo	**HAProxy**: `server-template` descubre tareas por DNS y permite round-robin con health checks.
Procesamiento	**Spark**: escalable, tolerante a fallos y disponible en el laboratorio. Pandas no cabe cómodamente en 3,8 GiB para 8,4 M de filas; Flink está orientado a streaming.
Almacenamiento	**Parquet + JSON**: separa el batch de la app, evita un esquema nuevo y permite que el dashboard funcione sin Spark encendido.
Visualización	**Tablas y barras CSS**: sin dependencias externas, funciona offline y se integra con el frontend existente.

II. Análisis

II-A. Dataset

Se usó **FitTrack-Synth**, un dataset sintético y reproducible generado por el propio equipo. El profesor autorizó explícitamente su uso. La decisión se justifica por privacidad (no contiene datos de personas reales), reproducibilidad (con la semilla 42 se obtiene el mismo dataset) y validación (el generador siembra patrones conocidos y publica una carpeta `clave_respuestas` para comprobar que el análisis los recupera).

El dataset tiene 100.000 usuarios y 8.462.080 filas crudas (741 MB) en cuatro CSV: usuarios, medidas, metas y rutinas. Cubre 78 semanas, del 2025-01-06 al 2026-07-05. Incluye suciedad controlada: duplicados exactos, nulos en medidas, fechas en `dd/mm/aaaa`, pesos en libras y pesos absurdos. El validador del generador ejecutó **24 chequeos OK, 0 con falla**.

La limitación principal es que los datos son sintéticos: los resultados no describen una población real, pero sí permiten evaluar el pipeline, la limpieza y la capacidad de recuperar patrones.

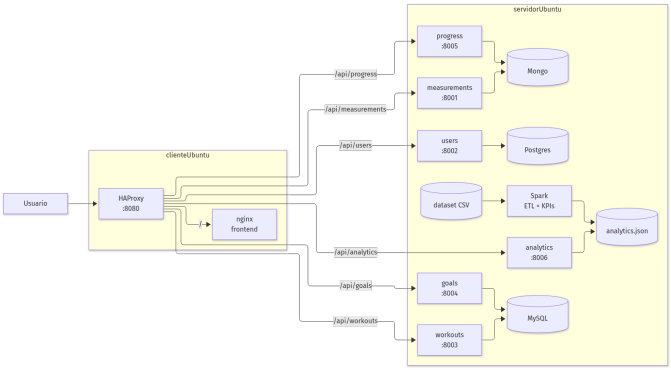


Figura 1: Componentes y flujo de una petición.

Cuadro II: Nodos del laboratorio.

Nodo	IP	Rol
`servidorUbuntu`	192.168.100.3	Swarm manager; microservicios, bases de datos, `analytics`, Spark master/worker
`clienteUbuntu`	192.168.100.2	Swarm worker; nginx y HAProxy

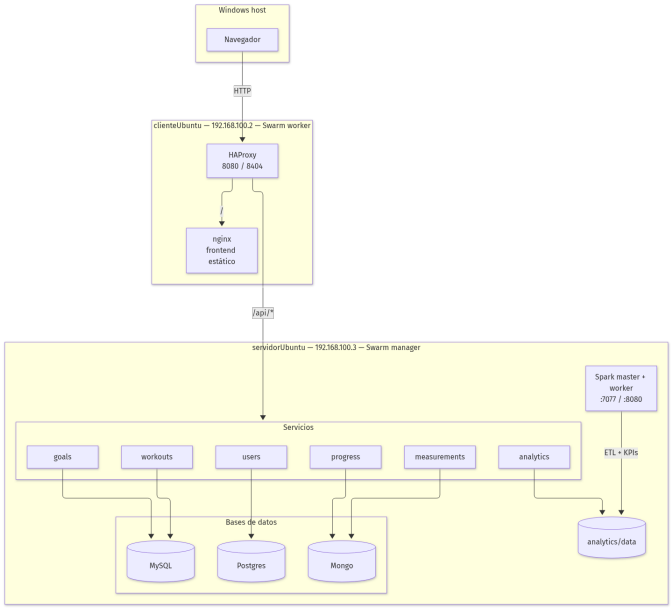


Figura 2: Despliegue en dos VMs y un clúster Spark.



Figura 3: Flujo del dataset al dashboard.

II-B. Alternativas evaluadas

II-C. Requisitos

Los requisitos se derivaron del enunciado: despliegue en clúster, escalabilidad, balanceo, pruebas de desempeño, dataset de gran escala, pipeline de análisis, reportes y dashboard. Se añadieron dos requisitos no funcionales: reproducibilidad (scripts y README) y operación con recursos limitados (dos VMs, 3,8 GiB en el servidor).

III. Diseño

III-A. Arquitectura de componentes

La aplicación se compone de: **frontend nginx**, que sirve el HTML/JS del dashboard y no proxea APIs; **HAProxy**, único entrypoint que enruta `/api/<servicio>/` y balancea entre réplicas; **users** (registro, login JWT y perfil; Postgres); **measurements** (medidas corporales; Mongo); **progress** (cálculo de progreso; Mongo); **workouts** (rutinas; MySQL); **goals** (metas; MySQL); **analytics** (API de solo lectura de los KPIs); y las bases **postgres**, **mongo** y **mysql**, con volúmenes `fittrack_*`.

El navegador llama a http://192.168.100.2:8080/api/...; HAProxy reescribe el prefijo y envía la petición al servicio correspondiente. Los servicios validan el JWT contra `users` y filtran por `user_id`. La pestaña de analítica llama a `/api/analytics/dashboard`.

III-B. Diagrama de despliegue

HAProxy y nginx se fijan al cliente; los servicios con estado y las bases de datos se fijan al servidor para que los volúmenes y bind mounts estén disponibles. La red overlay de Swarm conecta los dos nodos.

III-C. Pipeline de datos

El flujo es: (1) landing zone con los CSV crudos en `/root/fittrack/dataset/data`; (2) ETL con esquema explícito, limpieza y escritura de Parquet en `analytics/curated`; (3) KPIs con Spark SQL/DataFrame y escritura de `analytics.json`; (4) publicación por el servicio `analytics`; y (5) consumo por la pestaña “Analítica”.

III-D. Reglas de limpieza

III-E. KPIs y algoritmos

- **Retención**: semanas entre registro y última actividad; porcentaje con actividad a 4, 12 y 26 semanas, global y por cohorte mensual.
- **Adherencia**: sesiones por semana = rutinas / semanas activas; distribución en cubos.
- **Metas**: tasa de cumplimiento por objetivo y por tercil de ambición ($|\text{objetivo}/\text{inicial} - 1|$).
- **Peso**: primera y última medida válida con al menos 56 días de separación; cambio medio y correlación con sesiones/semana.
- **Estacionalidad**: registros y sesiones por mes; pico de enero.
- **Rutinas**: sesiones por tipo y grupo muscular; duración e intensidad medias.

III-F. Correspondencia dataset–aplicación

El dataset es analítico, no un volcado de las bases operativas. La correspondencia completa está en `dataset/CONSISTENCIA.md`; los puntos principales son:

Cuadro III: Reglas de limpieza aplicadas en el ETL.

Problema	Regla
Duplicados	Eliminar por `medida_id` y `rutina_id`.
Fechas	Aceptar ISO y `dd/mm/aaaa` con `try_to_date`.
Unidades	Convertir peso a kg con `unidad_peso`.
Pesos absurdos	Descartar fuera de 30–250 kg.
Nulos	Conservar nulos de cintura/brazo/pecho; las agregaciones los ignoran.
Metas de peso	Normalizar `valor_inicial` y `valor_objetivo` a kg.

- `objetivo_fitness` (`bajar_peso`, `ganar_musculo`, `mantener`, `resistencia`) corresponde a `FitnessGoalEnum` de la app (`weight_loss`, `muscle_gain`, `maintenance`, `endurance`).
- `direccion` (`subir`/`bajar`) coincide exactamente con el enum `goals.direccion`; es la dirección de una meta, no el objetivo del usuario.
- `tipo_medida` (`peso`, `cintura`, `brazo`, `pecho`) se mapea a `weight_kg`, `waist_cm`, `arm_cm`, `chest_cm`.
- `estado` (`cumplida`, `vencida`, `abandonada`, `activa`) es una etiqueta analítica; la app solo guarda `cumplida` y calcula el porcentaje.
- `duracion_min`, `num_ejercicios` e `intensidad` son analíticos: la tabla `routines` no los almacena.

No se cargan los 100.000 usuarios en la app: el dashboard consume los agregados por la API y las bases operativas conservan su esquema y sus validaciones.

IV. Implementación

IV-A. Parte 1: contenedores y Swarm

Cada microservicio tiene su `Dockerfile`. El stack (`docker-stack.yml`) define las imágenes, variables de entorno, volúmenes y restricciones de placement. Las bases de datos usan volúmenes nombrados; MySQL carga los esquemas de `workouts` y `goals` en el primer arranque.

HAProxy se construyó con `server-template` y el resolver DNS de Docker (`127.0.0.11`). Cada backend admite hasta seis réplicas y balancea en round-robin; las stats están en `:8404`.

Un problema encontrado: el nginx del frontend proxeaba `/api/*` a los nombres de servicio y fallaba al arrancar con `host not found in upstream "users"` cuando los servicios aún no existían. Se corrigió dejando nginx como servidor estático y HAProxy como único entrypoint de API (imagen `fittrack-nginx:v4`).

IV-B. Parte 2: Spark y analítica

El ETL (`spark/etl.py`) lee los CSV con esquema explícito, aplica las reglas de limpieza y escribe Parquet particionado por año. Los KPIs (`spark/analytics.py`) leen el Parquet y generan un JSON con secciones: dataset, limpieza, KPIs, retención, adherencia, metas, peso, estacionalidad, rutinas, ciudades y validación.

Cuadro IV: Resultados de limpieza del dataset.

Métrica	Valor
Filas crudas	8.462.080
Medidas curadas	2.881.725
Rutinas curadas	5.321.322
Duplicados de medidas	14.204
Duplicados de rutinas	26.776
Pesos inválidos	2.925
Fechas `dd/mm/aaaa` corregidas	8.703 + 16.025
Usuarios con peso en libras	14.659

Cuadro V: KPIs principales.

KPI	Valor
Usuarios	100.000
Activos a 12 semanas	54.758 (54,8 %)
Sesiones/semana	2,68
Metas cumplidas	16,96 %
Cambio medio de peso	−0,71 kg
Retención 4 / 12 / 26 semanas	86,4 / 51,6 / 33,3 %

Se desactivó ANSI (`spark.sql.ansi.enabled=false`) y se usó `try_to_date` para que los valores sucios no abortaran el job. El servicio `analytics` (FastAPI) lee el JSON por un bind mount de solo lectura y lo cachea por `mtime`; si Spark vuelve a escribir, la API sirve la versión nueva sin reiniciar.

El frontend añadió la pestaña “Analítica”, con tarjetas de KPIs, tablas y barras CSS. HAProxy añadió el backend `/api/analytics/*` hacia `analytics:8006`.

IV-C. Reproducibilidad

El repositorio incluye `README.md` con el paso a paso (stack, dataset, Spark, imágenes y pruebas), `spark/run_all.sh` y scripts individuales con memoria configurable, `tests/load/load_test.py` sin dependencias externas, `.env.example` y `dataset/` con generador, validador y diccionario.

V. Pruebas y resultados

V-A. Pruebas funcionales

Se probó el flujo completo contra `http://192.168.100.2:8080`: registro, login y `/me` (Postgres); creación y listado de medidas (Mongo); creación y listado de rutinas y metas (MySQL); cálculo de progreso (Mongo + llamada a measurements); y `GET /api/analytics/health`, `/kpis`, `/dashboard` y todas las secciones (HTTP 200).

Cuadro VI: Validación contra los patrones sembrados.

Patrón	Esperado	Obtenido
Abandono temprano	≈40 %	39,53 %
Pico de enero	≥1,4×	1,88×
Correlación bajar peso	$< -0{,}3$	−0,595
Correlación ganar músculo	$> 0{,}3$	+0,597
Metas ambiciosas (baja→alta)	baja > alta	29,6 / 13,9 / 7,4 %

Cuadro VII: Pruebas de carga: 1 réplica, 3 en un nodo y 3 en dos nodos.

Escenario	RPS	p50	p95	Errores
1 réplica	38,15	513,09 ms	654,58 ms	0
3 réplicas, 1 nodo	**72,05**	**272,48 ms**	**411,70 ms**	0
3 réplicas, 2 nodos	53,31–54,22	278–304 ms	839–871 ms	0

V-B. Limpieza

V-C. KPIs y validación

V-D. Carga, escalabilidad y estrés

Prueba de carga: 500 peticiones a `/api/measurements/`, concurrencia 20, desde el host Windows contra HAProxy.

El escalado en un mismo nodo mejora **1,89**× en RPS, −47 % en p50 y −37 % en p95. La primera medición con tres réplicas dio p95 de 3.485 ms porque el worker de Spark seguía vivo y el servidor usaba 913 MiB de swap; al detenerlo, la comparación fue limpia.

La prueba multi-nodo se hizo con `users` repartido 2+1 y `measurements` 1+2 entre `servidorUbuntu` y `clienteUbuntu`. La distribución funciona (0 errores), pero el throughput baja a 53–54 RPS: la red overlay y el worker de 2 cores pesan más que el beneficio de repartir en este laboratorio.

El RPS de `hey` cuenta solicitudes intentadas. El goodput baja a 53,6 RPS con 100 conexiones y a 37,2 RPS con 200, por los timeouts de cliente a 5 s. La meseta de ≈60 RPS y la aparición de timeouts desde 100 conexiones marcan el punto de saturación del laboratorio. Después del estrés, HAProxy volvió a mostrar todos los backends en `UP`.

V-E. Dashboard

La pestaña muestra 5 tarjetas de KPIs, retención por semanas y por cohorte, metas por objetivo, peso por objetivo, registros por mes, rutinas por tipo y una validación con etiquetas verdes. La captura completa está en `report/figuras/dashboard.jpeg`.

V-F. Discusión

Fortalezas: solución completa, reproducible y con evidencia; separación clara entre app y analítica; validación contra patrones conocidos; documentación de problemas y decisiones. **Limitaciones**: dataset sintético; un solo worker de Spark; las bases son instancias únicas; los KPIs son batch, no tiempo real;

Cuadro VIII: Prueba de estrés con `hey` (30 s por nivel).

Conexiones	RPS	p50	p95	Timeouts
50	59,17	605 ms	2.237 ms	0
100	58,57	726 ms	4.427 ms	152
200	61,05	1.575 ms	4.567 ms	797

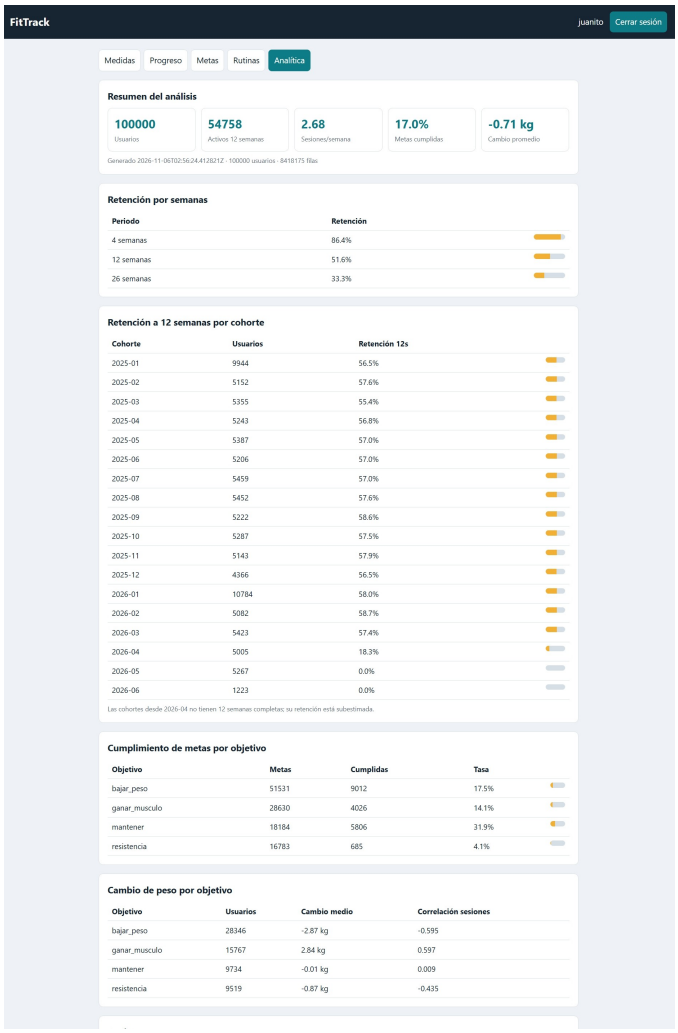


Figura 4: Parte superior de la pestaña “Analítica”: KPIs, retención y metas.

la distribución multi-nodo está probada, pero el throughput no mejora por la red overlay y el worker de 2 cores; el servidor compite con el stack. **Riesgos**: memoria y swap al correr Spark con el stack; tareas huérfanas de intentos anteriores; la rama `main` del repo no refleja la versión Docker.

VI. Conclusiones y trabajo futuro

Se desplegó FitTrack en Docker Swarm con balanceo, se construyó un pipeline de Spark para 8,4 M de filas y se publicaron los resultados en el dashboard. Las pruebas funcionales, de carga, de distribución multi-nodo y de estrés confirman que la solución cumple los objetivos. El escalado a tres réplicas en un nodo casi duplicó el throughput (72,05 RPS, 0 errores); la

distribución entre los dos nodos se demostró con 2+1 y 1+2 réplicas, aunque el rendimiento bajó a 53–54 RPS por la red overlay y el worker de 2 cores. El estrés marcó una meseta de $\approx$60 RPS y timeouts desde 100 conexiones.

Trabajo futuro: (1) Spark de dos nodos con un filesystem compartido (NFS) o HDFS para que el Parquet no quede repartido entre nodos y medir 1 vs 2 workers; (2) replicar las bases de datos (Postgres/MySQL/Mongo) para eliminar el punto único de fallo; (3) streaming con Structured Streaming para KPIs en tiempo real; (4) observabilidad con Prometheus/Grafana y alertas; (5) CI/CD para construir y publicar imágenes automáticamente; y (6) datos reales anonimizados, si el profesor lo permite, para contrastar los hallazgos.

REFERENCIAS

[1] Docker Inc., *Docker Swarm mode overview*. https://docs.docker.com/engine/swarm/

[2] HAProxy Technologies, *HAProxy Configuration Manual*. https://docs.haproxy.org/

[3] Apache Software Foundation, *Spark SQL, DataFrames and Datasets Guide*. https://spark.apache.org/docs/latest/sql-programming-guide.html

[4] Apache Software Foundation, *Structured Streaming Programming Guide*. https://spark.apache.org/docs/latest/structured-streaming-programming-guide.html

[5] FastAPI, *FastAPI documentation*. https://fastapi.tiangolo.com/

[6] FitTrack, repositorio del proyecto, rama `proyecto-final`. https://github.com/nicocpxmd/fittrack

[7] FitTrack-Synth, generador y validador del dataset, carpeta `dataset/`.

[8] IEEE, *IEEE Conference Template*. https://www.ieee.org/conferences/publishing/templates.html